



École Nationale Supérieure d'Arts et Métiers – Meknès

Université Moulay Ismaïl

Filière : Intelligence Artificielle et Technologies des Données

Rapport de projet – Maintenance Industrielle et Prédictive

PrognoSense

Plateforme Intelligente de Maintenance
Prédictive
basée sur l'Analyse Vibratoire et l'Intelligence
Artificielle

Réalisé par :

Souleymane DIALLO

Encadrant :

Pr. [Nom de l'encadrant]

Résumé

PrognSense est une plateforme logicielle de **maintenance prédictive industrielle** qui transforme l'analyse des signaux vibratoires en décisions de maintenance anticipées. La plateforme couvre l'intégralité de la chaîne de surveillance conditionnelle (CBM, *Condition-Based Maintenance*) : acquisition de signaux réels, extraction d'indicateurs vibratoires, évaluation de la sévérité selon la norme **ISO 10816/20816**, détection d'anomalies par apprentissage non supervisé, diagnostic spectral des défauts, calcul d'un indice de santé, pronostic de durée de vie restante, et déclenchement automatique d'ordres de travail transmis à la GMAO de l'entreprise.

Au-delà du diagnostic, la plateforme intègre une couche de **confiance et de gouvernance** : explicabilité des décisions, calibration, détection de dérive, journal d'audit horodaté, versioning des modèles avec retour arrière, et mesure du taux réel de fausses alarmes via la validation par un expert. Un **copilot** à base de modèle de langage, ancré sur une base de connaissances normative (RAG), rend l'expertise accessible en langage naturel. L'architecture est conçue pour passer à l'échelle (base time-series) et se connecter au terrain via les protocoles industriels standards (**OPC-UA, MQTT**).

Mots-clés : maintenance prédictive, analyse vibratoire, ISO 10816, détection d'anomalies, indice de santé, RUL, OPC-UA, GMAO, explicabilité, MLOps.

Table des matières

Résumé	1
1 Introduction	2
1.1 Contexte et problématique	2
1.2 Objectifs	2
1.3 Organisation du rapport	2
2 Contexte scientifique et technique	2
2.1 La maintenance conditionnelle (CBM)	2
2.2 Analyse vibratoire et normes	3
2.3 Positionnement vis-à-vis des solutions du marché	3
3 Architecture générale	3
3.1 Vue d'ensemble	3
3.2 Schéma de la chaîne de traitement	3
3.3 Technologies utilisées	4
4 Chaîne de traitement du signal	4
4.1 Acquisition et ingestion	4
4.2 Extraction d'indicateurs	4
4.3 Analyse spectrale et diagnostic	4
4.4 Sévérité ISO 10816/20816	4

5 Intelligence artificielle	5
5.1 Détection d'anomalies	5
5.2 Apprentissage du baseline par machine	5
5.3 Classification des défauts et pronostic	5
5.4 Confiance et gouvernance des modèles	5
6 Connectivité industrielle	5
6.1 Ingestion universelle	5
6.2 OPC-UA et MQTT	5
7 De l'alerte à l'action : la boucle fermée	6
7.1 Alertes	6
7.2 Ordres de travail et GMAO	6
8 Indicateurs de fiabilité et de performance	6
8.1 KPIs réels : mesurés, pas estimés	6
8.2 Retour sur investissement	6
8.3 Efficacité prédictive et fausses alarmes	6
9 Copilot IA et base de connaissances (RAG)	7
10 Sécurité, traçabilité et conformité	7
10.1 Authentification et rôles	7
10.2 Journal d'audit	7
11 Persistance et passage à l'échelle	7
11.1 Persistance	7
11.2 Architecture time-series scalable	7
12 Validation et résultats	7
13 Différenciation et apports	8
14 Limites et perspectives	8
15 Conclusion	8
Références	9

1 Introduction

1.1 Contexte et problématique

La maintenance industrielle a connu trois grandes approches successives. La maintenance **corrective** intervient après la panne : elle est simple mais coûteuse (arrêts non planifiés, dégâts collatéraux). La maintenance **préventive** intervient à intervalles fixes : elle réduit les pannes mais engendre des interventions inutiles et un gaspillage de pièces encore fonctionnelles. La maintenance **prédicative** (ou conditionnelle) intervient *au bon moment*, en se fondant sur l'état réel de la machine mesuré en continu.

Le défi est double : (i) détecter une dégradation *suffisamment tôt* pour planifier l'intervention, et (ii) le faire avec un *taux de fausses alarmes maîtrisé*, faute de quoi le système perd la confiance des équipes et finit par être ignoré.

1.2 Objectifs

Ce projet vise à concevoir une plateforme complète qui :

- surveille l'état de santé des machines à partir de signaux vibratoires réels ;
- diagnostique les défauts selon un référentiel normalisé (ISO 10816) ;
- anticipe les défaillances et estime la durée de vie restante ;
- transforme chaque alerte en action concrète (ordre de travail, GMAO) ;
- mesure sa propre fiabilité et trace toutes ses décisions ;
- reste accessible à des utilisateurs non spécialistes de la donnée.

1.3 Organisation du rapport

Le rapport présente d'abord le contexte scientifique (section 2) et l'architecture générale (section 3), puis détaille la chaîne de traitement du signal (section 4) et les modules d'intelligence artificielle (section 5). Les sections suivantes couvrent la connectivité industrielle (6), la boucle alerte → action (7), les indicateurs de fiabilité (8), le copilote (9), la sécurité et la traçabilité (10), la persistance et la scalabilité (11). Le rapport se clôt par la validation (12), le positionnement (13), les limites et perspectives (14) et la conclusion (15).

2 Contexte scientifique et technique

2.1 La maintenance conditionnelle (CBM)

La surveillance conditionnelle repose sur l'acquisition continue de grandeurs physiques (vibration, température, courant) et leur traitement pour estimer l'état de santé. La norme **ISO 13374** définit l'architecture de référence OSA-CBM en couches : acquisition, traitement du signal, détection d'état, évaluation de santé, pronostic, et aide à la décision. PrognSense suit cette logique de bout en bout.

2.2 Analyse vibratoire et normes

L'analyse vibratoire est l'outil central du diagnostic des machines tournantes. Les défauts produisent des signatures fréquentielles caractéristiques : balourd à la fréquence de rotation ($1\times$), désalignement à $2\times$, défauts de roulement aux fréquences BPFO/BPFI/BSF/FTF, défauts d'engrenage à la fréquence d'engrènement.

La sévérité globale est normalisée par la **vitesse vibratoire efficace (mm/s)** dans la bande 10–1000 Hz, classée en zones A (excellent), B (acceptable), C (insatisfaisant) et D (dangereux), selon **ISO 10816/20816** et la classe de la machine. D'autres normes encadrent le domaine : ISO 13373 (surveillance vibratoire), ISO 13379 (interprétation), ISO 13381 (pronostic) et ISO 18436 (certification des analystes).

2.3 Positionnement vis-à-vis des solutions du marché


Les solutions établies (SKF, Emerson, GE Bently Nevada, Augury, AspenTech Mtell) sont puissantes mais souvent propriétaires, fermées et coûteuses. PrognSense se distingue par une approche **ouverte, explicable et augmentée par IA générative**, déployable sur le parc de capteurs existant, comme détaillé en section 13.

3 Architecture générale

3.1 Vue d'ensemble

La plateforme suit une architecture en trois couches : un **backend** Python/FastAPI exposant une API REST et un canal temps réel WebSocket ; un **frontend** React/Vite pour l'interface opérateur ; une couche de **persistance** (base relationnelle, journaux). Le traitement du signal et les modèles d'IA sont encapsulés dans des modules métier réutilisables.

3.2 Schéma de la chaîne de traitement



3.3 Technologies utilisées

Couche	Technologies
Backend	Python 3, FastAPI, Uvicorn, Pydantic
Traitement signal	NumPy, SciPy (FFT, Hilbert, filtres Butterworth, intégration)
Intelligence artific.	scikit-learn (MLP, Random Forest, Isolation Forest, LOF), XGBoost, PyTorch (autoencoder, CNN)
Persistance	SQLAlchemy + SQLite (mode WAL), compatible PostgreSQL/TimescaleDB
Connectivité	API REST d'ingestion, OPC-UA (asyncua), MQTT (paho-mqtt), WebSocket
IA générative	API Mistral (copilot), recherche TF-IDF (RAG)
Sécurité	JWT (python-jose), hachage bcrypt (passlib)
Frontend	React, Vite, Axios, Recharts

4 Chaîne de traitement du signal

4.1 Acquisition et ingestion

La plateforme expose une couche d'ingestion **indépendante du fournisseur** : toute source (passerelle edge, automate, capteur sans fil, script de test) pousse une forme d'onde d'accélération via une API unique. Deux transports industriels standards sont pris en charge : **OPC-UA** et **MQTT** (section 6).

4.2 Extraction d'indicateurs

Pour chaque fenêtre de signal, la plateforme calcule des indicateurs :

- **temporels** : RMS, kurtosis, skewness, facteur de crête, valeur crête, crête-à-crête, écart-type ;
- **fréquentiels** : spectre FFT, fréquence dominante, entropie spectrale, énergie par bandes de fréquence ;
- **vitesse vibratoire (mm/s)** obtenue par intégration de l'accélération (filtrage passe-bande 10–1000 Hz).

4.3 Analyse spectrale et diagnostic

Le module spectral identifie les fréquences caractéristiques (BPFO, BPFI, BSF, FTF pour les roulements ; 1×, 2×, 3× pour balourd / désalignement / jeu) et confirme les défauts de roulement par **analyse d'enveloppe** (transformée de Hilbert). Il en déduit le type de défaut, sa sévérité et une recommandation d'action.

4.4 Sévérité ISO 10816/20816

La vitesse vibratoire efficace est classée en zones A/B/C/D selon la classe de machine (I à IV). Ce classement fournit un diagnostic **normalisé et défendable**, à la différence d'un indice ad hoc.

5 Intelligence artificielle

5.1 Détection d'anomalies

Deux approches complémentaires cohabitent. Un **autoencodeur** (PyTorch) entraîné sur des données saines détecte toute déviation par l'erreur de reconstruction. Un **ensemble de trois détecteurs** (Isolation Forest, Local Outlier Factor, Elliptic Envelope) vote par consensus : une anomalie n'est confirmée que si une majorité des détecteurs s'accordent, ce qui **réduit fortement les fausses alarmes**.

5.2 Apprentissage du baseline par machine

Pour chaque machine, la plateforme apprend de manière **non supervisée** la “signature saine” propre à cet équipement (statistiques multivariées). L'anomalie est mesurée relativement à ce baseline, et non à un jeu de données générique : l'approche s'adapte à chaque machine sans nécessiter d'historique de pannes.

5.3 Classification des défauts et pronostic

Plusieurs modèles de classification (Random Forest, XGBoost, MLP, CNN 1D) sont disponibles et comparés. Pour le pronostic, un modèle de régression estime la durée de vie restante (RUL) sur des données de dégradation. Un **Health Index** (0–100 %) fusionne le score d'anomalie, la dégradation et la tendance pour offrir un indicateur synthétique.

5.4 Confiance et gouvernance des modèles

La plateforme intègre : l'**explicabilité** (importance des indicateurs dans la décision) ; la **calibration** des probabilités ; la détection de **dérive** (concept drift) ; et une chaîne **MLOps** : chaque réentraînement crée une **version** archivée, avec possibilité de **retour arrière** (rollback) en cas de régression.

6 Connectivité industrielle

6.1 Ingestion universelle

Le point d'entrée `POST /api/ingest/signal` reçoit une forme d'onde réelle et la fait traverser tout le pipeline (indicateurs → ISO → anomalie vs baseline → diagnostic → Health Index → persistance). C'est ce qui transforme la plateforme d'un démonstrateur en un système connectable à de vraies machines.

6.2 OPC-UA et MQTT

Deux connecteurs alimentent cette ingestion :

- **OPC-UA** (standard de l'automatisme) : un connecteur lit périodiquement un nœud de mesure sur un serveur OPC-UA. Un serveur de démonstration a permis de valider la chaîne complète capteur → ingestion.
- **MQTT** (messagerie IIoT) : une passerelle publie ses mesures sur un topic que la plateforme consomme.

7 De l'alerte à l'action : la boucle fermée

7.1 Alertes

Le suivi de l'indice de santé déclenche des alertes au franchissement de seuils (surveillance, alerte, critique) et en cas de RUL faible.

7.2 Ordres de travail et GMAO

Lorsqu'une machine atteint un état critique (zone ISO D ou Health Index bas), la plateforme **crée automatiquement un ordre de travail** priorisé (avec dédoublement), qui peut être **poussé vers la GMAO** de l'entreprise (SAP PM, IBM Maximo, Infor) via un connecteur webhook. L'alerte devient ainsi une intervention planifiée et tracée. Des notifications par e-mail complètent le dispositif.



8 Indicateurs de fiabilité et de performance

8.1 KPIs réels : mesurés, pas estimés

Un point méthodologique central distingue PrognoSense : les indicateurs de fiabilité sont **mesurés sur l'historique réel des interventions**, conformément à leur définition, et non estimés à partir de la simulation.

- **MTBF** = temps de fonctionnement cumulé / nombre de pannes réelles ;
- **MTTR** = temps total de réparation / nombre de réparations ;
- **Disponibilité** = $\text{MTBF} / (\text{MTBF} + \text{MTTR})$.

Un MTBF ne se déduit pas d'un capteur : il se constate sur les pannes effectives. Tant qu'aucune donnée n'est saisie, la plateforme n'affiche aucun chiffre, par honnêteté.

8.2 Retour sur investissement

À partir des interventions, la plateforme estime les arrêts évités et les économies réalisées, fournissant un argumentaire de ROI exploitable par la direction.

8.3 Efficacité prédictive et fausses alarmes

En croisant les alertes émises avec les pannes réelles, la plateforme calcule la **précision**, le **rappel** et le **délai d'anticipation (lead-time)**. Un mécanisme de **validation par l'expert** (vrai/faux positif) permet de mesurer le **vrai taux de fausses alarmes**, indicateur de confiance essentiel.

9 Copilot IA et base de connaissances (RAG)

Un assistant conversationnel, propulsé par un modèle de langage (Mistral), répond en langage naturel et a accès au contexte temps réel de la flotte. Il est **ancré sur une base de connaissances** (normes ISO, guide des signatures de défaut, interprétation des indicateurs) par une recherche de similarité (RAG) : ses réponses citent les sources documentaires, ce qui les rend précises et **traçables**. Le copilot démocratise ainsi l'expertise d'un analyste vibratoire auprès des techniciens.

10 Sécurité, traçabilité et conformité

10.1 Authentification et rôles

L'accès est protégé par authentification (JWT, mots de passe hachés bcrypt) avec une gestion de rôles (administrateur / utilisateur) restreignant les actions sensibles (réentraînement, injection, rollback).

10.2 Journal d'audit

Chaque décision de l'IA et chaque alerte est **enregistrée et horodatée** (prédiction, machine, confiance), avec persistance sur disque survivant aux redémarrages. Ce journal répond aux exigences de **conformité** et d'**audit** : toute alerte peut être justifiée a posteriori, rien n'est une "boîte noire".

11 Persistance et passage à l'échelle

11.1 Persistance

Les états machines, alertes, événements de maintenance, versions de modèles et ordres de travail sont persistés via SQLAlchemy. SQLite est utilisé par défaut (mode WAL pour la concurrence), sans dépendance d'infrastructure.

11.2 Architecture time-series scalable

Pour un parc réel, la plateforme est **prête à basculer sur TimescaleDB** (PostgreSQL + extension time-series) sans modification du code : seule la variable de connexion change. Une lecture **agrégée (downsampling)** et une politique de **rétenion** sont fournies, ainsi qu'un **docker-compose** et une documentation de mise à l'échelle.

12 Validation et résultats

Les principales fonctionnalités ont été validées de bout en bout :

Fonctionnalité	Validation
Sévérité ISO	Signal d'essai 1 g à 50 Hz → 22,3 mm/s, zone D (cohérent avec le calcul théorique)
Baseline machine	Signal sain → anomalie $\approx 5\%$; signal dégradé → $\approx 96\%$
Ingestion + GMAO	Signal critique ingéré → ordre de travail P1 créé automatiquement
KPIs réels	MTBF, MTTR, disponibilité calculés depuis les interventions saisies
OPC-UA	Serveur de démonstration → connecteur → ingestion validée
Copilot RAG	Question “pic à 2×” → réponse “désalignement” avec sources citées
Lecture agrégée	Plusieurs centaines de points bruts → agrégation horaire

13 Différenciation et apports

PrognSense ne cherche pas à rivaliser en largeur avec les suites propriétaires, mais à occuper une position claire :

- **Ouverture** : connectable à n'importe quel capteur (OPC-UA, MQTT), sans verrouillage propriétaire.
- **Diagnostic normalisé** : langage ISO 10816, défendable par un fiabiliste.
- **Explicabilité et confiance** : SHAP, calibration, audit, taux de fausses alarmes mesuré.
- **Copilot ancré** : expertise accessible en langage naturel, réponses sourcées.
- **Boucle fermée** : de l'alerte à l'ordre de travail dans la GMAO.

14 Limites et perspectives

Les principales limites actuelles et pistes d'évolution sont :

- validation sur des **données de terrain réelles** (au-delà des jeux de données de référence et des signaux de démonstration) ;
- modèles **hybrides physiques + données** (physics-informed) par type de machine ;
- **apprentissage fédéré** multi-sites ;
- formalisation complète de l'architecture **OSA-CBM (ISO 13374)** ;
- durcissement cybersécurité industrielle (**IEC 62443**), SSO, RBAC fin.

15 Conclusion

PrognSense démontre qu'une plateforme de maintenance prédictive peut être à la fois **rigoureuse** (diagnostic normalisé ISO, indicateurs de fiabilité mesurés), **actionnable** (boucle fermée vers la GMAO), **digne de confiance** (explicabilité, audit, fausses alarmes mesurées) et **accessible** (copilot en langage naturel), tout en restant **ouverte** et **connectable au terrain**. Le projet établit une base solide, prête à être validée sur des données industrielles réelles et à évoluer vers une solution de référence.

Références

1. ISO 10816 / ISO 20816 — *Vibration mécanique — Évaluation des vibrations des machines par mesures sur les parties non tournantes.*
2. ISO 13374 — *Surveillance et diagnostic d'état des machines — Traitement, communication et présentation des données (OSA-CBM).*
3. ISO 13373 — *Surveillance et diagnostic d'état des machines — Surveillance des vibrations.*
4. ISO 13381 — *Pronostic.*
5. ISO 18436 — *Qualification et évaluation du personnel.*
6. Documentation FastAPI, scikit-learn, PyTorch, asyncua, paho-mqtt, TimescaleDB.